

Análise da Capacidade de uma Rede Neural de Memória Associativa com Arquitetura de Elementos Processados Recursivamente

Humberto Sandmann
humberto.sandmann@poli.usp.br

Marco Túlio Carvalho de Andrade
marco.andrade@poli.usp.br

*Escola Politécnica da Universidade de São Paulo
Departamento de Engenharia de Computação e Sistemas Digitais
Laboratório de Engenharia de Conhecimento (KNOMA)
Sala C2-37, 05508-900 SP, Brasil.*

Abstract

This paper addresses a research about a neural network for associative memory built with architecture of Recursive Processing Elements Neural Network (RPE). Experiments were made for analysis the recovery pattern capacity of architecture RPE and its were contrasted with results of architecture Hopfield. The results show a relation between the number of iterations, number of storage patterns and noise level in recovery pattern capacity by a neural network with architecture RPE, and graphics were built for best understand and illustrate this relationship.

1 Introdução

O uso de redes neurais no processo de construção de memórias associativas tem se tornado tema de intensa investigação nas pesquisas atualmente, grande parte dos avanços nessas pesquisas são derivados de resultados e observações científicas de estudos dos modelos biológicos de redes neurais.

Para simular a capacidade de armazenamento de uma memória associativa biológica em modelos matemáticos de redes neurais, diversas arquiteturas foram propostas e utilizadas com sucesso, o modelo utilizado com mais frequência foi proposto por Hopfield [1], assim passando a ser conhecido como Arquitetura de Rede Neural Hopfield. Mas este modelo trata comportamentos matemáticos bem definidos, visando a busca por um modelo mais próximo das características biológicas foram propostos modelos artificiais que simulam outras características comportamentais das redes neurais biológica, entre estas característica esta o com-

portamento caótico, tem se mostrado muito importante para o armazenamento e recuperação de informações no modelo biológico.

Foram propostos então diversos modelos para simular este comportamento, entre eles o proposto por [2] que apresenta um modelo com comportamento caótico, denominado Chaotic Neural Network (CNN) ou Rede Neural Caótica. Neste modelo é possível trabalhar com parâmetros matemáticos que simulam o comportamento caótico, o período refratário, e entre outras características comportamentais dos neurônios, porém por outro lado este mesmo modelo possui uma implementação bastante custosa e com alta complexidade computacional.

Procurando reproduzir o comportamento caótico em redes neurais artificiais, e também reduzir a complexidade computacional do processo, foi proposto um modelo onde cada neurônio possui uma função recursiva onde existe a presença do comportamento caótico [3], assim em substituição às funções tradicionais de ativação do neurônio, foi proposto fazer uso de uma função recursiva que apresenta caos. Este modelo é conhecido como Recursive Processing Elements Neural Network (RPE) ou Rede Neural de Elementos Processados Recursivamente, onde cada nó da rede (elemento) é um neurônio que pode desempenhar oscilações de valores em períodos caóticos ou assintóticos.

Este trabalho tem como propósito testar a capacidade de recuperação de uma arquitetura de rede neural projetada com RPE. Em outras palavras, dado um padrão de informação a ser armazenada pela rede neural, esta deve recuperá-lo mesmo quando houver influência de ruídos, o que é facilmente encontrado em um ambiente de comportamento dinâmico, este trabalho esta focado nesta capacidade de recuperação do padrão. Foram também esti-

medidas das quantidades de iterações necessárias em uma rede neural de RPE para se obter uma informação recuperada de boa qualidade.

Nas próximas seções foram apresentados: o formato de armazenamento de informações proposto por Hopfield, para armazenamento de informações em redes neurais; o funcionamento de uma rede neural de RPE; alguns experimentos computacionais realizados para testar e avaliar a capacidade da arquitetura; e finalmente algumas discussões e conclusões sobre o trabalho.

2 Processo de Armazenamento

Um sistema inteligente tem que ser capaz de recuperar e reconhecer informações, para tal competência se torna necessário que o modelo suporte então o armazenamento de padrões. Este armazenamento de informações pode ser feito por uma matriz de correlação proposta por Hopfield [1]. Onde esta matriz armazena as diferenças de similaridades entre um padrão de informação armazenado e os demais, assim como a correlação de todos os nós do padrão, a matriz de correlação pode ser calculada como sendo

$$\mathbf{W} = \left(\sum_{\mu=1}^M \xi_{\mu} \xi_{\mu}^T \right) - M\mathbf{I} \quad (1)$$

onde M é o número de padrões a serem armazenados pela rede neural, ξ é um padrão de informações, e $\mathbf{I}$ é uma matriz identidade que ajusta os pesos de correlação do próprio nó. Por consequência cada valor da matrix $\mathbf{W}$ pode ser escrito como w_{ij} , que representa o valor de correlação entre o nó i e o nó j de todos os padrões armazenados.

Uma vez calculada a matriz de correlação que armazena os padrões de informações, podemos então projetar uma rede neural que recupere os dados armazenados na matriz de correlação $\mathbf{W}$. A seção a seguir explica o funcionamento básico de recuperação utilizando uma rede neural de RPE.

3 Redes Neurais de Elementos Processados Recursivamente

Redes neurais de Elementos Processados Recursivamente são de um tipo de arquitetura de redes neurais onde cada neurônio artificial é ativado por uma função linear recursiva, e não por uma função não-linear, como é tradicionalmente encontrado em diversas arquiteturas de redes neurais [4]. Isso permite que cada nó da rede possa desenvolver um comportamento diferente dos demais, estando em períodos caóticos durante algumas iterações do processo de recuperação da informação, ou

em períodos fixos assintóticos em outros. Toda essa dinâmica permite uma melhor acomodação do valor do nó em busca de uma informação estabilizada na matriz de correlação $\mathbf{W}$, ou da informação armazenada.

A função linear aplicada a cada nó tem que desenvolver um comportamento caótico em algum momento no decorrer do processo de recuperação, neste trabalho foi utilizada a função logística como função linear de cada nó [3], [5] e [4]. Para o uso de outras funções são necessárias algumas adaptações, como por exemplo, no modelo proposto por [6], a função logística recursiva aqui utilizada é dada por

$$x(t+1) = \rho x(t)(1 - x(t)) \quad (2)$$

Na equação 2, o termo x se refere a um nó da rede neural, logo todo o conjunto de nós da rede pode ser descrita através da matriz $\mathbf{x}$; o índice t é utilizado para representar o tempo de iteração, onde $x(t+1)$ é o estado de x posterior a $x(t)$; e ρ é o parâmetro de bifurcação, sendo este o gerador de caos no nó.

Como cada nó da rede depende apenas de seu estado anterior, não é possível forçar a rede neural se estabilizar em uma informação apenas modificando o valor de x , mas é possível tornar o valor do parâmetro de bifurcação ρ tendencioso a um valor de informação desejado em x .

Uma alteração no parâmetro de bifurcação ρ basta para que o valor do nó oscile entre valores de períodos caóticos ou períodos fixos assintóticos. A Figura 1 ilustra esse fenômeno apenas para um nó isolado, e como todos os nós da rede utilizada neste trabalho não são dependentes dos valores uns dos outros nós, ou seja, cada nó é independente, logo o comportamento de todos os outros nós são semelhantes ao mostrado na Figura 1.

Neste trabalho foi iniciada a oscilação de periodicidade de visitação em grandes períodos (maior que 2), ou até mesmo em períodos caóticos, pois quando for conveniente a rede pode então estabilizar o nó em estados de apenas 2 períodos, já que este trabalho processa sinais com valores digitais. E estes podem ser representados por valores bipolares 1 e -1 , como ilustrado pelos pontos A e B respectivamente na Figura 1.

O padrão que entra na rede neural é representado por ξ_I , assim cada nó do padrão de entrada é simbolizado por $\xi_{I,i}$. Similarmente o padrão de saída da rede neural ou padrão recuperado é representado por ξ_R , onde então cada nó do padrão de saída é simbolizado por $\xi_{R,i}$, logo i é o índice de cada nó da rede para os dois padrões.

Ambos os padrões, tanto o de entrada quando o recuperado são representados por valores polarizados, mas uma rede neural de RPE trabalha de forma analógica, sendo necessário fazer uma conversão do padrão de entrada digital ξ_I para um padrão analógico, logo o valor




Figura 1: Diagrama de bifurcação para a recursão do mapa logístico: $x(t + 1) = \rho x(t)(1 - x(t))$. O eixo horizontal representa o valor do parâmetro de bifurcação ρ , e o eixo vertical os valores visitados após o período de estabilização pela variável x . Os pontos marcados como A e B são exemplos de visitação em período 2 que esta estável quando $\rho = 3,25$ e x oscila entre $A = 0,81$ e $B = 0,50$ [3]. As duas linhas tracejadas representam a faixa de trabalho para o valor de ρ , com $\min_{\rho} = 3,25$ e $\max_{\rho} = 3,80$ [7].

bipolar -1 passa a ser mapeado pela constante B e o valor bipolar 1 conseqüentemente é mapeado pela constante A .

Com a conversão a a rede neural passa a interagir, executando a função recursiva para cada nó da rede, busca assim uma convergência para um dos padrões armazenados. Essa convergência é dada pela modificação gradual no valor do parâmetro de bifurcação, este ajuste é proposto por [7], sendo dado por

$$d_i = -\gamma(x_i - k_1) \left(\sum_{j=1}^N w_{ij}(x_j - k_1) \right) + k_2 \quad (3)$$

Logo a Equação 3 permite calcular o ajuste a ser aplicado em cada parâmetro de bifurcação ρ para cada iteração da rede. Na Equação 3, o termo d_i é o valor da diferença a ser aplicado ao ρ_i específico, o termo N é o total de nós do padrão, a constante k_1 um ajuste de polarização do valor de cada nó com relação a média de todos os nós do padrão, logo k_1 pode ser dado pela média dos valores de $x(t)$, e a constante k_2 é apenas um ajuste para compensar uma mínima diferença em caso de pesos zero. Já o termo γ é um fator de normaliza-

ção para ajuste dos pesos entre os nós armazenados na matriz de correlação $\mathbf{W}$, podendo ser calculado como segue

$$\gamma = \frac{1}{\max_{ij} |\mathbf{W}|} \quad (4)$$

Agora com o valor de diferença calculado, este é aplicado ao parâmetro de bifurcação ρ_i do respectivo nó x_i , sendo

$$\Delta\rho_i = d_i\eta - \lambda \quad (5)$$

onde d_i é o valor da diferença (veja Equação 3), η é uma taxa de aprendizado sobre o valor da diferença d_i , neste trabalho η é uma constante 1 , e λ é um valor de amortização para quando d_i for zero, neste trabalho foram escolhidos valores de amortização na faixa de $0,01$ até $0,06$. O índice i indica que para cada nó da rede existe um valor diferente de parâmetro de bifurcação ρ .

Para garantir que o valor de ρ_i esteja dentro das especificações da Figura 1, foram estabelecidos limites de faixas de trabalho para o valor ρ , sendo $\min_{\rho} = 3,25$ e $\max_{\rho} = 3,80$ para todos os nós da rede neural. Assim é garantido que após a estabilização da rede, os nós estejam operando em período 2, já que a cada iteração a rede tende a decrementar o valor de cada ρ_i .

A estabilização da rede é dada pelo critério do limite de iterações no índice t , (este parâmetro limite é representado por T). Ao atingir a estabilização é necessário definir novamente os valores de saída para ξ_R , mapeando os valores analógicos de $\mathbf{x}(T)$ em valores polarizados, o mapeamento é realizado utilizando a função sinal.

$$\xi_{R,i} = \text{signal}(x_i(T) - \bar{x}(T)) \quad (6)$$

Na Equação 6, $\xi_{R,i}$ é $+1$ se $f(\cdot)$ for maior que zero, e $\xi_{R,i}$ é -1 se $f(\cdot)$ for menor que zero. Permitindo que as redes neurais de RPE funcionem como redes neurais associativas, ou seja, capazes de recuperar padrões mesmo quando estes se apresentam com certo nível de ruído [7].

4 Capacidade de Recuperação

Em uma rede neural com arquitetura RPE, o término do processo de recuperação de um padrão de informação é dado pelo limite de T iterações, quando uma rede atinge o valor limite de T iterações a informação de saída tem que ser validada, afim de verificar se esta informação recuperada esta correta ou não. Isto permite levantar uma taxa de acerto de recuperação, que esta ligada à capacidade de armazenamento da matriz de correlação, pois quanto maior a taxa de acerto maior o espaço disponível na matriz para armazenar novas informações.

Essa taxa pode ser calculada com base no número de nós da rede pelo número de padrões a ser armazenado,

este aspecto de capacidade foi explorado de forma similar para redes neurais de Hopfield por [1].

Outro fator que influencia na capacidade de recuperação dos dados, além da relação entre número de nós pelo número de padrões, é a disposição vetorial dos dados armazenados, isto é, quando temos muitos vetores (nós) ortogonais entre si, a rede consegue recuperar a informação com maior facilidade, caso contrário esse processo é mais lento e difícil. Sendo que o padrão de entrada pode até convergir para um padrão armazenado, mas com T maior do que o limite estipulado, consequentemente o padrão recuperado irá conter ruídos.

A seguir foram apresentados alguns experimentos computacionais para testar a capacidade de recuperação das memórias associativas e buscar uma relação entre a performance de recuperação com o número de iterações necessárias para convergência de uma rede neural de RPE.

5 Experimentos Computacionais

Os experimentos apresentados neste trabalho demonstram comparações de recuperações entre os padrões de entrada e os padrões de saída, utilizando redes neurais como memórias associativas.

A geração dos valores para os padrões a serem armazenados foram realizadas de maneira aleatória, buscando evitar problemas de ortogonalidades tendenciosas para as amostras. Todos os padrões possuem dimensões de 100 nós, e a geração de ruídos nos padrões de entrada foram realizadas pela inversão de uma porcentagem dos bits das informações digitais originais.

As taxas de ruídos adicionadas aos padrões de entrada, variam entre as faixas de 0% a 30% (em passos de 10%), sendo que a informação digital original pode estar corrompida dentro dessa margem de erro em posições aleatórias. A escolha dessa faixa de porcentagem de erro é proposital, pois valores com grandes ruídos talvez seriam mais bem aproveitados se fossem considerados como novos padrões, assim podendo ser aprendido ou ignorado pela rede (uma abordagem para este tema onde o ruído é tratado como um novo padrão a ser aprendido foi explorado por [7]).

O primeiro experimento mostra a capacidade média de recuperação dos padrões de entrada com ruídos, os padrões foram recuperados por uma rede neural de arquitetura Hopfield, e os resultados podem ser observados na Figura 2, este experimento serve de base para comparação com a arquitetura da rede neural de RPE.

Na Figura 2, o eixo horizontal mostra o número de padrões armazenados na matriz de correlação $\mathbf{W}$ (veja Equação 1), e no eixo vertical a porcentagem de acerto médio para cada nível de ruído descrito pela curva. Este experimento foi realizado com 20 amostras aleatórias




Figura 2: A figura mostra a capacidade média de recuperação de um padrão armazenado dado um padrão de entrada oscilando com diversas taxas de ruídos, em uma rede de arquitetura de Hopfield. Este experimento foi realizado com 20 amostras aleatórias de padrões de entrada para cada nível de ruído e número de padrões armazenados na matrix de correlação.

para cada número de padrão armazenado, logo quando a matriz de correlação possui muitos padrões armazenados o número de amostras se torna maior do que quando possui poucos padrões armazenados, deixando os resultados mais precisos na medida que possui mais padrões armazenados.

O segundo experimento é uma replica do primeiro experimento, porém este foi realizado utilizando uma rede neural com arquitetura de RPE na recuperação dos padrões armazenados.

Os dados armazenados e recuperados apesar serem aleatórios, também são os mesmos do primeiro experimento. A Figura 3 apresenta os resultados obtidos com a arquitetura com RPE, neste caso foi estabelecido o valor limite de $T = 150$.

Para comparar as duas arquiteturas e suas capacidade de recuperação foi realizada a média de acertos para cada um dos dois experimentos anteriormente descritos. A Figura 4 descreve o resultado das médias de acertos, sendo que em alguns casos a arquitetura de Hopfield apresenta melhor desempenho que a arquitetura com RPE, e em outros casos a arquitetura de RPE tem um melhor desempenho.

Para melhor entender a relação entre a capacidade de recuperação e o número de iterações necessárias, se torna interessante levantar um gráfico que mostre o número médio de iterações para uma determinada




Figura 3: A figura mostra a capacidade média de recuperação de um padrão armazenado dado um padrões de entrada oscilando com diversas taxas de ruídos, em uma rede de arquitetura de RPE. Este experimento foi realizado com 150 ciclos e 20 amostras aleatórias de padrões de entrada para cada nível de ruído e número de padrões armazenados na matrix de correlação.




Figura 4: A figura apresenta as médias de desempenho de acerto para as duas arquiteturas de redes neurais.

condição da matriz de correlação $\mathbf{W}$ (ou número de padrões armazenados), e a taxa de ruído presente nos padrões de entrada. Para este quarto experimento foram utilizadas 50 amostras para cada número de padrão armazenado e estabelecido como critério de parada a recuperação do padrão correto ou número máximo de iterações 150, a Figura 5 demonstra os resultados obtidos.




Figura 5: Esta figura ilustra o número médio de iterações necessárias para recuperação de um padrão armazenado sob a degradação de diversas taxas de ruídos e iteração máxima em 150 ciclos.

É possível observar que quanto maior o número de padrões armazenado na matriz de correlação pior é o desempenho de recuperação, o mesmo ocorre com a taxa de ruídos.

Para tentar aumentar a performance de recuperação do experimento anterior, este foi refeito de maneira que ocorresse número maior de iterações, estabelecendo como limite de iterações $T = 1500$, e também com um número de 20 amostras por padrões armazenados. O resultado deste experimento é mostrado pela Figura 6, onde é notar que permitindo um número maior de iterações o padrão de entrada acaba tendendo para um padrão armazenado, logo o padrão foi recuperado. Apesar disto, em alguns casos esse número de iterações pode ser muito grande, o que acaba tornando o processo mais lento, como foi notado, por exemplo, quando o número de padrões armazenados esta em torno de 20 padrões.

6 Conclusões

Com base nos experimentos realizados foi possível concluir que uma rede neural de arquitetura com RPE possui uma boa taxa de acerto, quando comparada com




Figura 6: Esta figura ilustra o número médio de iterações necessárias para recuperação de um padrão armazenado sob a degradação de diversas taxas de ruídos e iteração máxima em 1500 ciclos.

uma tradicional rede neural de arquitetura Hopfield.

Também é possível notar o desempenho de uma arquitetura de rede neural de RPE tende a melhorar seu desempenho em função do número de iterações. Isso torna a recuperação independente da distribuição espacial das amostras de padrões armazenados, mas apenas para um número de iterações realmente muito grande.

Os gráficos apresentados permite também levantar uma curva que correlaciona a capacidade de armazenamento pela rede neural, com o número de iterações necessárias para sua recuperação, isso ajuda no cálculo de um possível custo para o uso dessa técnica em memórias associativas artificiais, assim como permite também verificar sua viabilidade em determinadas aplicações, já que os resultados demonstram maior tempo para convergência.

Agradecimentos

Os autores gostariam de agradecer ao Prof. Dr. Emílio Del Moral Hernandez pelas discussões e sugestões que sempre acrescentaram o trabalho, ao Sr. Leandro Augusto da Silva pela revisão e sugestões, e também ao suporte oferecido pela Escola Politécnica da Universidade de São Paulo.

Referências

- [1] S. Haykin. *Neural networks: a comprehensive foundation*, 2/E. Prentice Hall, Inc., New York, NY, 1999.

- [2] K. Aihara, T. Takabe, and M. Toyoda. Chaotic neural networks. In *Physics Letters A, Elsevier*, volume 144, pages 333–340, 1990.
- [3] E. Del-Moral-Hernandez. Neural networks with chaotic recursive nodes: techniques for the design of associative memories, contrast with hopfield architectures, and extensions for time-dependent inputs. In *Neural Networks, Elsevier*, volume 16, pages 675–682, 2003.
- [4] E. Del-Moral-Hernandez. Studing neural of bifurcation recursive processing elements - quantitative methods for architecture design and performance analysis. In *Lecture Notes in Comp. Science, Springer*, volume 2084, page 546, 2001.
- [5] K. Kaneko. *The Coupled Map Lattice: Introduction, Phenomenology, Lyapunov Analysis, Thermodynamics and applications*. John Wiley & Sons, 1993.
- [6] S. Ishii, K. Fukumizu, and S. Watanabe. Associative memory using spatiotemporal chaos. In *Proceedings of 1993 International Joint Conference on Neural Networks*, pages 2638–2641, 1993.
- [7] E. Del-Moral-Hernandez, H. Sandmann, and L. A. Silva. Pattern recovery in networks of recursive processing elements with continuous learning. In *Appear to Proceedings of 2004 International Joint Conference on Neural Networks*, July 2004.